

Konzeption und Evaluation eines
Multi-Agenten-Systems zur automatisierten
Migration von imperativer LO-VC Logik zu
deklarativer AVC Syntax am Beispiel der msg
systems ag

Torben Dörrer

3. Juni 2026

Inhaltsverzeichnis

Abkürzungsverzeichnis	iii
1 Einleitung	1
2 Theoretische Grundlagen	2
2.1 Domänenspezifische Grundlagen: SAP Variantenkonfiguration	2
2.1.1 Einführung in die logische Architektur der Variantenkonfiguration	2
2.1.2 Die klassische Variantenkonfiguration (LO-VC) im Kontext der Systemtransformation	4
2.1.3 Die moderne Architektur (AVC) und das Constraint Paradigma	5
2.2 Generative künstliche Intelligenz im Software Engineering . . .	6
2.2.1 Large Language Models für Quellcode	6
2.2.2 Limitationen monolithischer Ansätze	9
2.3 Multi-Agenten-Systeme(MAS)	11
2.3.1 Definition und kognitive Architekturen	11
2.3.2 Kollaborative Agenten-Muster	14
2.3.3 Entwicklungs-Frameworks für MAS	16
3 Related Work	19
4 Experteninterview	23
4.1 Zielsetzung und Erkenntnisinteresse	23
4.2 Methodisches Forschungsdesign	23
4.3 Datenerhebung und Auswertung	25
4.4 Ergebnisse der Befragung	26
4.4.1 Kognitive Altlasten und historischer Code	26
4.4.2 Paradigmenwechsel und syntaktisches Umdenken . . .	27
4.4.3 Fragmentierung manueller Prozessschritte	27
4.4.4 Limitierungen bestehender Standard-Tools	27
4.4.5 Manueller Aufwand und Fehleranfälligkeit im Testprozess	28

4.4.6	Zeitliche Metriken und Identifikation von Flaschenhälsen	28
4.5	Implikationen für die Systemarchitektur	29
4.5.1	Funktionale Anforderungen aus der Expertenperspektive	29
4.5.2	Architektonische Paradigmen und Beratungsansatz . .	29
4.5.3	Konzeptionelle Notwendigkeit einer Multi-Agenten-Struktur	30
4.5.4	Quantitative Zielvorgaben für die Systemvalidierung . .	30
Anhang	Anhang	35
Anhang	Datenauswertung der Experteninterviews	36

Abkürzungsverzeichnis

KMAT	konfigurierbare Materialstamm
Super BOM	konfigurierbare Maximalstückliste
AVC	Advanced Variant Configuration
LO-VC	Logistics Variant Configuration
KI	künstliche Intelligenz
ML	Machine Learning
CSP	Constraint Satisfaction Problem
LLMs	Large Language Models
ICL	In-Context Learning
MAS	Multi-Agenten Systeme

Kapitel 1

Einleitung

Beispieltext für die Einleitung.

Kapitel 2

Theoretische Grundlagen

Um die Konzeption und Entwicklung eines KI-gestützten Migrationssystems fundiert nachvollziehen zu können, ist ein tiefgreifendes Verständnis der zugrundeliegenden technologischen Domänen unerlässlich. Dieses Kapitel legt das theoretische Fundament der vorliegenden Arbeit, indem es die wesentlichen Konzepte der SAP-Variantenkonfiguration, der generativen künstlichen Intelligenz sowie der Orchestrierung von Multi-Agenten-Systemen systematisch aufarbeitet.

2.1 Domänenspezifische Grundlagen: SAP Variantenkonfiguration

2.1.1 Einführung in die logische Architektur der Variantenkonfiguration

In der modernen Fertigungsindustrie erfordert die Abbildung kundenindividueller Produkte hochflexible Systemstrukturen. Die grundlegende informationstechnische Idee der Variantenkonfiguration besteht darin, ein konfigurierbares Produkt – wie beispielsweise einen Personenkraftwagen – nicht als unzählige, separat gepflegte Endprodukte anzulegen, sondern als ein zentrales Grundmodell, das durch diverse Ausprägungen (wie Lackierung, Motorisierung oder Bereifung) spezifiziert wird. Diese Ausprägungen sind durch ein logisches Regelwerk miteinander verknüpft, um technische und kaufmännische Restriktionen abzubilden. Da die Kombination aller möglichen Merkmalsausprägungen die Anzahl der finalen Varianten schnell in die Millionen oder, in extremen Fällen der Anlagenfertigung, bis in den Bereich von Quadrillionen (10^{24}) treiben kann, ist die Anlage diskreter Stammdaten für jede einzelne physische Ausprägung in der IT-Praxis unmöglich (Blumöhr et al., 2023, S.

86).

Als systemtechnische Antwort auf diese kombinatorische Explosion fungiert im SAP-System der sogenannte *konfigurierbare Materialstamm* (KMAT). Dieser dient als universaler Platzhalter, unter dem die gesamte Variantenvielfalt eines Produkts informationstechnisch zusammengefasst wird (Blumöhr et al., 2023, S. 90). Um diese Vielfalt in einer sogenannten Bewertungsoberfläche abzubilden, greift die SAP-Architektur auf drei zentrale Strukturkomponenten zurück (Blumöhr et al., 2023, S. 90 - 96):

- **Merkmale:** Sie definieren die spezifischen Eigenschaften eines Produkts (wie beispielsweise die Lackierung oder die Traglast eines Gabelstaplers).
- **Variantenklassen:** Diese dienen der logischen Bündelung der Merkmale und werden direkt dem KMAT zugeordnet.
- **Konfigurationsprofil:** Dieses fungiert als übergeordnetes Steuerungselement, das die Stammdaten zusammenhält und den Konfigurationsprozess maßgeblich regelt.

Ein zentrales Paradigma der SAP-Variantenkonfiguration zur Bewältigung dieser Komplexität ist das sogenannte Maximal-Prinzip. Anstatt ein Produkt aus einzelnen Modulen additiv zu einem 100 %-Modell zusammenzusetzen, basiert die Architektur auf einem subtraktiven 150 %-Modell. Hierfür wird eine *konfigurierbare Maximalstückliste* (Super BOM) eingesetzt. Diese umfasst sämtliche Bauteile und Komponenten, die für jedwede theoretisch mögliche Variante des Produkts jemals benötigt werden könnten (Blumöhr et al., 2023, S. 169). Während des Konfigurationsprozesses können dieser Stückliste keine neuen Elemente hinzugefügt, sondern lediglich nicht benötigte Komponenten herausgefiltert werden.

Die logische Brücke zwischen der kaufmännischen Konfiguration und der technischen Fertigung bildet das *Beziehungswissen*. Metaphorisch gesprochen übersetzt dieses Regelwerk das kundenseitige „Wünschen“ in der Bewertungsoberfläche in das fertigungsseitige „Erhalten“ in Form der ausgedünnten Stückliste (Blumöhr et al., 2023, S. 101). Konkret wird dies durch Steuerungsmechanismen wie *Auswahlbedingungen* realisiert. Wenn ein Kunde beispielsweise aus einem Angebot von sechs Motoren einen spezifischen Antrieb wählt, determinieren die Auswahlbedingungen des Beziehungswissens, dass die fünf nicht gewählten Motoren aus der finalen Fertigungsstückliste eliminiert werden.

Die Zusammenhänge dieser fundamentalen Architekturkomponenten – vom konfigurierbaren Materialstamm über die Bewertungsoberfläche bis hin zur

Maximalstückliste und dem steuernden Beziehungswissen – sind in Abbildung ?? schematisch zusammengefasst.

(Hier kommt die Grafik rein)

2.1.2 Die klassische Variantenkonfiguration (LO-VC) im Kontext der Systemtransformation

Um die technologische Entwicklung der Variantenkonfiguration zu verstehen, ist zunächst eine Einordnung in die Evolution der SAP-Systemlandschaften erforderlich. Während das bisherige Kernprodukt *SAP ERP* (oft auch als *SAP R/3* bezeichnet) über Jahrzehnte den Standard darstellte, markiert *SAP S/4HANA* eine fundamentale Neuausrichtung der Softwarearchitektur, insbesondere durch die Nutzung der In-Memory-Datenbanktechnologie (Blumöhr et al., 2023, S. 28). In diesem Zuge wurde für die Variantenkonfiguration ein neues technologisches Fundament geschaffen.

Der Begriff *Logistics Variant Configuration* (LO-VC) dient heute primär als Retronym, um die klassische Art der Konfiguration von der neuen *Advanced Variant Configuration* (AVC) abzugrenzen (Blumöhr et al., 2023, S. 32). Obwohl LO-VC in aktuellen S/4HANA-Installationen (On-Premise und Private Cloud) aus Gründen der Abwärtskompatibilität weiterhin verfügbar ist, gilt sie technologisch als veralteter Standard.

LO-VC basiert dabei auf einem prozeduralen Paradigma, das historisch bedingt oft durch einen „Learning-by-Doing“-Ansatz in den Unternehmen gewachsen ist. Dies führte dazu, dass Modelle häufig unnötig komplex durch den Einsatz von Prozeduren und Aktionen anstatt leistungsfähigerer Constraints gestaltet wurden (Blumöhr et al., 2023, S. 58). Der Wechsel zu AVC wird in der Literatur daher nicht nur als technisches Upgrade, sondern als strategische Notwendigkeit beschrieben, die durch folgende Kernaspekte begründet wird:

- **Rückkehr zum Standard und Vereinfachung:** AVC stellt den künftigen Standard dar. Die Migration bietet Unternehmen die Chance, historisch gewachsene, schwer wartbare „Spaghetti-Logiken“ zu dekonstruieren und durch eine moderne, leichter wiederverwendbare Modellierung zu ersetzen (Blumöhr et al., 2023, S. 57).
- **Abbildung moderner Geschäftsmodelle:** Klassische LO-VC Strukturen sind primär auf den reinen Verkauf von Produkten (SD-Kontext) ausgelegt. Moderne Strategien wie das *Solution Bundling* (Kombination aus Produkt, Dienstleistung und Abonnements) lassen sich im Standard nur über AVC und die damit verknüpften neuen Objektträger wie die *Solution Quote* abbilden (Blumöhr et al., 2023, S. 59).

- **Technologische Überlegenheit:** AVC nutzt mit *Gecode* eine moderne Constraint-Solving-Engine, die im Gegensatz zur sequenziellen LO-VC-Logik analytische Prinzipien verfolgt und damit eine deutlich höhere Performance und Flexibilität bietet (Blumöhr et al., 2023, S. 59).
- **Zukunftsfähigkeit:** Innovative Technologien aus den Bereichen *künstliche Intelligenz* (KI) oder des *Machine Learning* (ML) sowie moderne Auswertungsmethoden via *CDS-Views* werden nativ für AVC entwickelt. Eine nachträgliche Integration in die veraltete LO-VC-Architektur gleicht lediglich einer „Renovierung“, die nie den Leistungsumfang einer Neuentwicklung erreichen kann (Blumöhr et al., 2023, S. 61).
- **Human-Resource-Aspekt:** Angesichts des Fachkräftemangels ist die Arbeit mit moderner Softwarearchitektur ein entscheidender Faktor bei der Gewinnung von Talenten. Die Wartung einer über 25 Jahre alten Softwarelösung ist im Vergleich zur Vorreiterrolle in einer intelligenten Fertigungsumgebung auf Basis aktueller Technologie weniger attraktiv für qualifizierten Nachwuchs (Blumöhr et al., 2023, S. 60).

Zusammenfassend lässt sich festhalten, dass der Verbleib in der LO-VC-Welt zwar kurzfristig Transformationsaufwände vermeidet, langfristig jedoch das Risiko erhöht, den Anschluss an technologische Innovationen zu verlieren und den Aufwand für eine spätere Migration durch das wachsende technologische Delta exponentiell zu vergrößern (Blumöhr et al., 2023, S. 61).

2.1.3 Die moderne Architektur (AVC) und das Constraint Paradigma

Die Antwort auf die konzeptionellen Schwächen und technischen Limitierungen der klassischen Variantenkonfiguration bildet die Einführung der AVC in SAP S/4HANA. Um den stetig wachsenden Anforderungen an Performance und Modellierungskomplexität (wie beispielsweise in den *Make-to-Order*- oder *Engineer-to-Order*-Szenarien) gerecht zu werden, vollzieht SAP mit AVC nicht nur ein syntaktisches Update, sondern einen fundamentalen informationstechnischen Paradigmenwechsel unter der Haube der Konfigurations-Engine.

Während das bisherige LO-VC-System, wie in Kapitel 2.1.2 beschrieben, auf einer iterativen, imperativen Abarbeitung von Befehlen und Prozeduren basierte, nutzt AVC einen grundlegend deklarativen Lösungsansatz. Das technologische Herzstück der AVC-Architektur bildet ein neu integrierter *Constraint Solver* namens *Gecode*, eine ursprünglich quelloffene Softwarebibliothek, die in Zusammenarbeit mit dem Fraunhofer-Institut ITWM tief

in den SAP-Standard eingebettet und für komplexe Produktkonfigurationen erweitert wurde (Blumöhr et al., 2023, S. 35).

Der Einsatz dieser Engine überführt den Konfigurationsprozess mathematisch in ein sogenanntes *Constraint Satisfaction Problem* (CSP). Ein CSP wird in der Informatik grundlegend definiert als ein System, das aus „einer Menge von Variablen, einer Menge von Domänen [sowie] einer Menge von Constraints, die zulässige Kombinationen von Werten spezifizieren“ (eigene Übersetzung nach Russell, 2010, S. 180) besteht.

Dieser deklarative Ansatz bringt tiefgreifende Auswirkungen auf die Benutzerführung und die Systemstabilität mit sich. Sobald ein Anwender während der Konfiguration in der Benutzeroberfläche einen Wert für ein bestimmtes Merkmal wählt, schränkt die Gecode-Engine die Domänen (Wertebereiche) aller anderen abhängigen Merkmale in Echtzeit ein. Anstatt einen Fehler erst nach der sequenziellen Abarbeitung einer Prozedur auszuwerfen, eliminiert der Solver unmögliche Auswahlmöglichkeiten präventiv aus dem Suchraum. Dies verhindert effektiv die Entstehung inkonsistenter Konfigurationen (Blumöhr et al., 2023, S. 35).

Darüber hinaus bietet AVC erweiterte Simulations- und Analysemöglichkeiten, wie beispielsweise den *Dependency Trace*. Dieser ermöglicht es Konstrukteuren und Modellierern, in einem *Inspector Panel* genau nachzuvollziehen, welches Constraint für die Einschränkung eines bestimmten Merkmals verantwortlich ist (Blumöhr et al., 2023, S. 37).

Zusammenfassend markiert AVC durch die Gecode-Engine den Wechsel von der Frage „Wie berechne ich die Variante Schritt für Schritt?“ hin zu der Frage „Welche globalen Bedingungen müssen für ein gültiges Endprodukt erfüllt sein?“. Genau dieser Paradigmenwechsel vom Imperativen zum Deklarativen stellt Unternehmen bei der Systemmigration vor die immense Herausforderung, historisch gewachsene, prozedurale Altlasten semantisch zu dekonstruieren und in das neue, netzwerkbasierte Constraint-Paradigma zu transformieren.

2.2 Generative künstliche Intelligenz im Software Engineering

2.2.1 Large Language Models für Quellcode

In den vergangenen Jahren haben KI-Systeme, insbesondere aus dem Bereich der generativen Künstlichen Intelligenz, einen rasanten und tiefgreifenden technologischen Aufstieg erlebt. Im Zentrum dieser Entwicklung stehen sogenannte *Large Language Models* (LLMs). Fundamental betrachtet handelt es

sich dabei um tiefe künstliche neuronale Netze, die auf massiven Textkorpora trainiert wurden, um das statistisch wahrscheinlichste nächste Zeichen (Token) in einer Sequenz vorherzusagen. Was als Werkzeug für rein statistische Textvervollständigungen begann, hat sich durch enorme Skalierung zu mächtigen kognitiven Architekturen entwickelt. Diese Modelle dringen zunehmend in den Bereich des Software Engineerings vor und verändern die Art und Weise, wie Software entworfen, analysiert und transformiert wird, grundlegend. Um das Potenzial dieser Technologie für automatisierte Migrationsprozesse zu verstehen, ist ein grundlegendes Verständnis der zugrundeliegenden mathematisch-technischen Prinzipien sowie der Methoden zu deren Steuerung erforderlich.

Die Transformer-Architektur und der Aufmerksamkeitsmechanismus

Die heutige Generation marktbeherrschender Sprachmodelle basiert fast ausnahmslos auf der wegweisenden Transformer-Architektur, die durch Vaswani et al. (2017) eingeführt wurde. Der entscheidende informationstechnische Durchbruch des Transformers liegt in der Abkehr von früheren Modellen wie rekurrenten neuronalen Netzen oder Faltungsnetzen. Während diese älteren Architekturen Eingabesequenzen – wie natürlichen Text oder Quellcode – streng sequenziell, mithin Zeichen für Zeichen oder Zeile für Zeile verarbeiten mussten, bricht der Transformer dieses lineare Paradigma auf.

Dies gelingt durch den sogenannten *Self-Attention-Mechanismus*. Dieser Mechanismus erlaubt es dem Modell, alle Elemente (Token) einer Sequenz zeitgleich und vollständig parallel zu verarbeiten. Mathematisch berechnet das Netzwerk für jedes Token innerhalb eines Kontextes einen Gewichtungsfaktor relativ zu allen anderen Token der Sequenz. Dadurch wird bestimmt, wie viel „Aufmerksamkeit“ einem Wort oder Code-Snippet im Verhältnis zum Rest des Textes beigemessen werden muss.

Im Kontext des Software Engineerings löst diese Architektur das fundamentale Problem weitreichender Abhängigkeiten (*Long-Range Dependencies*). Wenn beispielsweise eine Variable am Anfang einer umfangreichen Code-Datei deklariert und hunderte Zeilen später in einer komplexen logischen Bedingung aufgerufen wird, verkürzt der Transformer den informationellen Pfad im Netzwerk auf eine konstante Länge. Der Self-Attention-Mechanismus berechnet die direkte strukturelle Verknüpfung zwischen Deklaration und Aufruf unabhängig von ihrer physischen Distanz im Dokument. Quellcode wird somit nicht als linearer Text, sondern als ein Netz simultan interagierender logischer Einheiten interpretiert.

In-Context Learning und Few-Shot Prompting

Die Fähigkeit, tiefe semantische Strukturen zu erfassen, wirft die Frage auf, wie diese Modelle ohne immensen Rechenaufwand für spezifische, proprietäre Aufgabensteuerungen eingesetzt werden können. Historisch erforderte die Anpassung eines neuronalen Netzes an eine neue Domäne ein ressourcenintensives *Fine-Tuning*, bei dem die internen Gewichte des Modells durch überwachtetes Lernen angepasst wurden. Moderne LLMs weisen jedoch ab einer kritischen Skalierungsgröße sogenannte emergente Fähigkeiten auf, die dieses Paradigma verschieben.

Wie durch Brown et al. (2020) nachgewiesen wurde, verhalten sich ausreichend große Sprachmodelle weitgehend aufgabenunabhängig (*task-agnostisch*). Anstatt die Modellparameter dauerhaft zu modifizieren, findet das Lernen direkt zur Laufzeit innerhalb des Eingabefensters statt – ein Konzept, das als *In-Context Learning* (ICL) bezeichnet wird. Das Modell nutzt sein im Pre-Training erworbenes, generalistisches Strukturwissen, um eine neue Aufgabe fließend und unmittelbar aus den im Prompt gegebenen Mustern abzuleiten.

Eine der mächtigsten Methoden des ICL ist das *Few-Shot Prompting*. Hierbei werden dem Modell im Eingabetext neben der eigentlichen Instruktion einige wenige konkrete Demonstrationen (Musterbeispiele) übergeben, die eine Eingabe und die dazugehörige korrekte Zielausgabe abbilden. Ohne dass ein einziges Gradientenupdate im neuronalen Netz stattfindet, adaptiert das LLM die logische Analogie zwischen den Beispielen und wendet diese auf die neue, ungesehene Zielaufgabe an. Für komplexe Domänen bietet dies den Vorteil, dass Modelle flexibel und agil gesteuert werden können, solange der Prompt die notwendigen logischen Leitplanken bereitstellt.

Das Paradoxon der Code-Übersetzung

Für den konkreten Einsatz generativer KI im Software Engineering liefert die umfassende Systematisierung von Zheng et al. (2023) eine wesentliche differenzierende Erkenntnis bezüglich der Modellauswahl. Entgegen der intuitiven Annahme, dass für Programmieraufgaben spezialisierte Modelle stets vorzuziehen sind, zeigt sich in empirischen Studien ein zweigeteiltes Bild.

Auf der einen Seite existieren hochspezialisierte, verhältnismäßig kleine Sprachmodelle (*Code LLMs*), die exklusiv auf riesigen Quellcode-Korpora trainiert wurden. Beim Agieren auf einer „grünen Wiese“ – mithin bei der isolierten Generierung von Standardfunktionen oder der automatisierten Erstellung von Unit-Tests – übertreffen diese dedizierten Code-Modelle die gigantischen, allgemeinsprachlichen Modelle oft deutlich. Sie weisen eine hohe syntaktische Präzision auf und sind in ihrer Ausführung hochgradig effizient.

Auf der anderen Seite verkehrt sich dieses Leistungsverhältnis ins Gegenteil, sobald die Aufgabe in den Bereich der Code-Übersetzung (*Code Translation*) fällt. Bei der Migration bestehender Logik von einer Quellsprache oder einem Paradigma in eine andere Zielarchitektur dominieren führende, generalistische Großmodelle (wie beispielsweise GPT-4) die spezialisierten Code-Modelle signifikant.

Die wissenschaftliche Begründung hierfür lässt sich aus der Natur der Problemstellung ableiten: Eine Software-Migration ist kein rein syntaktisches Substitutionsproblem, bei dem lediglich Schlüsselwörter ausgetauscht werden. Es handelt sich vielmehr um ein komplexes Abstraktions- und Logikproblem. Das Modell muss den semantischen Kern, die implizite Absicht und die vernetzten Bedingungen des Altsystems vollständig durchdringen, diese in eine sprachunabhängige logische Repräsentation abstrahieren und anschließend unter den restriktiven Bedingungen des Zielparadigmas neu formulieren. Für derart vielschichtige logische Schlussfolgerungen (*Reasoning*) ist das breite Weltwissen und die schiere kognitive Kapazität der großen, generalistischen Modelle unabdingbar, während rein syntaxfokussierte Code-Modelle an den abstrakten Paradigmenwechseln scheitern.

2.2.2 Limitationen monolithischer Ansätze

Obgleich die im vorherigen Abschnitt beschriebenen Fähigkeiten moderner Großmodelle zur semantischen Erfassung und Übersetzung von Quellcode beachtlich sind, stößt der praktische Einsatz in industriellen Software-Engineering-Projekten an fundamentale Grenzen. In der Praxis und der aktuellen Forschung werden Ansätze, bei denen eine komplexe Aufgabe in einer einzigen Interaktionsschleife – mithin über einen einzelnen, isolierten Eingabeaufforderungs-Befehl (*Single-Prompt* oder *One-Shot-Verfahren*) – gelöst werden soll, als *monolithische Ansätze* bezeichnet. Um die Notwendigkeit fortgeschrittener, verteilter Architekturen zu begründen, müssen die systemimmanenten Schwachstellen dieser monolithischen Herangehensweise auf zwei Ebenen analysiert werden: der algorithmischen Komplexität der Logikketten und der strukturellen Komplexität systemweiter Abhängigkeiten.

Die Komplexitätsfalle und das probabilistische Paradigma

Die primäre algorithmische Limitierung monolithischer Prompts bei logisch anspruchsvollen Aufgaben wurde bereits frühzeitig durch OpenAI im Rahmen der Vorstellung des Codex-Modells empirisch dokumentiert. Wie Chen et al. (2021) nachweisen, sind LLMs hervorragend in der Lage, isolierte, in sich

geschlossene Programmieraufgaben zu lösen, sofern die Spezifikation klar umrissen ist.

Das Leistungsvermögen bricht jedoch mathematisch nachweisbar ein, sobald eine Spezifikation lange Ketten sequenzieller oder verschachtelter Operationen verlangt (*Chaining-Problem*). Die Autoren zeigen, dass die Erfolgsquote des Modells mit zunehmender Anzahl logisch verknüpfter Bausteine innerhalb der Anforderung exponentiell abfällt (Chen et al., 2021). Für die Migration historisch gewachsener SAP-Regelwerke (wie dem klassischen *Variant Configuration*-Modell LOVC) ist diese Erkenntnis von kritischer Bedeutung: Solche Altsysteme bestehen typischerweise aus hochgradig verschachtelten, prozeduralen Abhängigkeiten und logischen Verzweigungen. Ein monolithischer Prompt zwingt das Modell, diese gesamte kognitive Last simultan zu verarbeiten und den Zielcode in einem einzigen autoregressiven Durchlauf fehlerfrei zu generieren. Dies überschreitet die inhärenten Fähigkeiten zur logischen Vorausschau des Modells, da es Token für Token auf Basis von Wahrscheinlichkeiten generiert, ohne eine echte logische Tiefenprüfung vorzunehmen.

Darüber hinaus beleuchtet das Paper eine fundamentale Schwäche des probabilistischen Charakters von Sprachmodellen. Die in diesem Paper vorgestellte Metrik *pass@1* – welche die Wahrscheinlichkeit beschreibt, dass ein einzelner generierter Code-Entwurf funktional korrekt ist – ist bei komplexen Aufgabenstellungen extrem gering. Erst durch das wiederholte Generieren unabhängiger Stichproben (*pass@k*) und eine anschließende externe Verifizierung steigt die Erfolgsquote signifikant an (Chen et al., 2021). Ein monolithischer Ansatz bietet jedoch keinerlei inhärente Mechanismen für ein solches iteratives *Sampling* oder eine automatisierte Qualitätskontrolle, wodurch fehlerhafte Syntax oder logische Fehlschlüsse unkorrigiert in das Zielergebnis einfließen.

Das Scheitern an systemweiten Abhängigkeiten und fehlendem Umgebungs-Feedback

Während die Arbeit von Chen et al. (2021) die Schwächen auf Ebene einzelner Funktionen aufzeigt, skaliert der aktuellere *SWE-bench*-Benchmark von Jimenez et al. (2024) diese Analyse auf das Niveau realer, industrieller Software-Repositories. Im Rahmen dieses Frameworks wurden führende Sprachmodelle mit echten, komplexen Problemstellungen aus großen Open-Source-Projekten konfrontiert, bei denen Änderungen nicht isoliert, sondern über Systemgrenzen hinweg durchgeführt werden mussten.

Die Ergebnisse dieses Benchmarks offenbaren ein klares Defizit monolithischer Großmodelle: Selbst hochgradig leistungsfähige, kommerzielle State-of-the-Art-Modelle wie GPT-4 oder die Claude Modellfamilie (Anthropic) waren im monolithischen *Single-Prompt*-Setting überfordert und konnten weit unter

5% der realen Software-Probleme erfolgreich lösen (Jimenez et al., 2024). Die Autoren identifizieren zwei Hauptursachen für dieses Scheitern:

1. **Mangelndes Verständnis globaler Abhängigkeiten:** Monolithische LLMs scheitern an der Identifikation von *Cross-File-Dependencies*. Sie sind zwar in der Lage, den lokal übergebenen Code-Kontext zu modifizieren, überblicken jedoch nicht, welche Auswirkungen diese Modifikation auf andere, im Kontext nicht enthaltene Klassen, Schnittstellen oder Datenstrukturen des Gesamtsystems hat. Bei einer SAP AVC-Migration, die auf einem global vernetzten, deklarativen *Constraint*-Netzwerk basiert, führt dieser blinde Fleck unweigerlich zu fatalen Inkonsistenzen im Gesamtsystem.
2. **Fehlen einer interaktiven Ausführungsumgebung:** Ein monolithischer Prompt agiert als reine Text-zu-Text-Transformation in einer isolierten Umgebung (Black-Box). Dem Modell fehlt jeglicher Zugriff auf einen Compiler, einen Interpreter oder Testprotokolle. In der realen Softwareentwicklung ist die fehlerfreie Code-Erstellung jedoch ein hochgradig interaktiver, iterativer Prozess. Ohne die Möglichkeit, den generierten Code testweise auszuführen und das daraus resultierende Compiler-Feedback dynamisch zu interpretieren, ist das Modell gezwungen, die syntaktische Korrektheit blind zu erraten.

Zusammenfassend lässt sich konstatieren, dass monolithische KI-Ansätze aufgrund der exponentiellen Fehleranfälligkeit bei langen Logikketten, des Mangels an systemweiter Kontextverarbeitung und der Isolation von echten Ausführungsumgebungen für komplexe Architektur-Transformationen ungeeignet sind. Diese wissenschaftlich dokumentierte Forschungslücke erfordert den Übergang von isolierten Prompts hin zu dynamischen, interaktiven Multi-Agenten-Systemen, die in der Lage sind, Aufgaben modular aufzuteilen und durch kontinuierliche Feedbackschleifen zu validieren.

2.3 Multi-Agenten-Systeme(MAS)

2.3.1 Definition und kognitive Architekturen

Um die im vorherigen Abschnitt dokumentierten Limitationen monolithischer Sprachmodelle – insbesondere den exponentiellen Leistungsabfall bei langen Logikketten und das Fehlen systemweiter Kontrollmechanismen – informationstechnisch aufzulösen, etabliert sich in der modernen Informatik das Paradigma der *Multi-Agenten Systeme* (MAS). Die fundamentale Kernidee

dieses Ansatzes besteht darin, eine komplexe Gesamtaufgabe nicht einem einzelnen, allumfassenden Prompt zu übergeben, sondern die kognitive Last auf ein Kollektiv spezialisierter, künstlicher Entitäten – sogenannte KI-Agenten – zu verteilen, welche autonom und kollaborativ an der Erreichung eines vordefinierten Endziels arbeiten.

Der Begriff des LLM-basierten Agenten

In der klassischen Informatik wird ein Agent traditionell als eine Entität definiert, die in der Lage ist, ihre Umwelt durch Sensoren wahrzunehmen und auf diese mittels Aktuatoren einzuwirken, um rationale Entscheidungen zu treffen (Russell, 2010, S. 36). Im Kontext moderner generativer KI verschiebt sich dieses Konzept grundlegend: Das primäre „Gehirn“ und die zentrale Rechenmaschine des Agenten ist ein LLM.

Ein LLM-basierter Agent unterscheidet sich von einem klassischen, rein reaktiven Chatbot durch ein erhöhtes Maß an Autonomie, Intentionalität und Werkzeugnutzung. Technisch wird ein solcher Agent instanziiert, indem ein Basis-Sprachmodell mit einem spezifischen System-Prompt (*Instruction Engineering*) versehen wird, welcher seine Identität, seine Verhaltensregeln und seine Zielsetzung exakt formuliert. Darüber hinaus wird der Agent mit Schnittstellen zu externen Werkzeugen (*Tools*) oder Datenquellen ausgestattet.

Ein wesentliches Merkmal von Multi-Agenten-Strukturen ist die architektonische Flexibilität ihrer Orchestrierung. Es existiert kein starrer, mathematisch vorgegebener Standard, wie ein solches System strukturiert sein muss. Die Ausgestaltung des Kontrollflusses und der Kommunikationspfade obliegt dem Systemarchitekten. Dabei lassen sich zwei fundamentale Organisationsformen unterscheiden:

1. **Statische Orchestrierung:** Der Entwickler definiert im Vorfeld unveränderliche Kommunikationsketten und deterministische Ablaufpläne (z. B. Agent A muss seine Ausgabe zwingend an Agent B übergeben).
2. **Dynamische Autonomie:** Das Multi-Agenten-System erhält die inhärente Fähigkeit, zur Laufzeit eigenständig zu entscheiden, ob, wann und welche Sub-Agenten oder Werkzeuge zur Lösung eines auftretenden Teilproblems aktiviert werden müssen.

Die kognitive Kern-Anatomie nach Wang et al.

Ogleich die konkrete softwaretechnische Implementierung je nach verwendetem Entwicklungs-Framework variieren kann, hat sich in der wissenschaftlichen Literatur eine universelle, standardisierte kognitive Architektur für autonome

Agenten herauskristallisiert. Wie Wang et al. (2024) im Rahmen einer umfassenden Systematisierung nachweisen, lässt sich die funktionale Anatomie eines leistungsfähigen LLM-basierten Agenten trennscharf in vier interagierende Kernmodule unterteilen:

- **Profiling-Modul (Rollen-Spezifität):** Dieses Modul legt fest, welche spezifische Persona, Expertise und Verhaltensrestriktionen der Agent adaptiert. Durch die Zuweisung einer dedizierten Rolle (z. B. „SAP-AVC-Architekt“) wird der Suchraum des Sprachmodells im Pre-Training-Wissen fokussiert, was die Relevanz der Ausgaben drastisch erhöht.
- **Memory-Modul (Gedächtnis-Strukturen):** Das Gedächtnis sichert die zeitliche Konsistenz des Agenten. Es unterteilt sich in ein Kurzzeitgedächtnis (*Short-term Memory*), welches den aktuellen Konversationskontext puffert, und ein Langzeitgedächtnis (*Long-term Memory*), das es dem Agenten erlaubt, historische Informationen, erfolgreich gelöste Aufgaben oder domänenspezifisches Wissen dauerhaft zu persistieren.
- **Planning-Modul (Aufgaben-Dekonstruktion):** Komplexe Fragestellungen überfordern die direkte autoregressive Textgenerierung. Das Planungs-Modul befähigt den Agenten, ein globales Endziel autonom in überschaubare, logisch aufeinander aufbauende Teilaufgaben (*Sub-tasks*) zu zerlegen und Prioritäten zu setzen.
- **Action-Modul (Werkzeug-Exekution):** Dieses Modul bildet die Brücke zur Außenwelt. Es übersetzt die textuellen Intentionen des Sprachmodells in konkrete API-Aufrufe, Datenbankabfragen oder Code-Ausführungen und führt damit die im Planungs-Schritt definierten Aufgaben real aus.

Das ReAct-Paradigma zur dynamischen Fehlerkorrektur

Innerhalb des für Migrationsprozesse besonders kritischen Planungs- und Aktionsmoduls droht bei rein prozeduralen Prompts die Gefahr einer unkontrollierten Fehlerfortpflanzung. Um eine adaptive und verlässliche Problemlösungskompetenz zu garantieren, bildet das von Yao et al. (2022) eingeführte *ReAct*-Paradigma (*Reasoning and Acting*) das theoretische Fundament moderner Agenten-Kognition.

Das ReAct-Muster bricht die isolierte, statische Natur klassischer Sprachmodelle auf, indem es eine kontinuierliche, interaktive Schleife aus drei sequenziellen Phasen erzwingt:

Thought (Gedanke) $\longrightarrow$ Action (Handlung) $\longrightarrow$ Observation (Beobachtung)

In der *Thought*-Phase nutzt der Agent das LLM, um den aktuellen Zustand verbal zu analysieren, logische Schlussfolgerungen zu ziehen und eine spezifische Handlungsabsicht zu formulieren. In der darauffolgenden *Action*-Phase wird diese Absicht durch den Aufruf eines externen Werkzeugs – beispielsweise eines Compilers – exekutiert. Die entscheidende Innovation liegt in der *Observation*-Phase: Das reale Feedback der Umgebung (z. B. eine syntaktische Fehlermeldung des Compilers) wird abgefangen und als neuer Text-Kontext in das Modell zurückgespeist.

Das Modell verarbeitet diese Beobachtung in der nächsten *Thought*-Phase, reflektiert den Fehler aktiv und passt seinen nachfolgenden Aktionsplan dynamisch an. Dieser zirkuläre Prozess des *Self-Refinements* verhindert, dass der Agent – wie ein monolithischer Prompt – blind fehlerhafte Code-Strukturen halluziniert oder falsche Annahmen unkorrigiert fortschreibt. Das ReAct-Paradigma ermöglicht somit eine faktenbasierte, empirisch überprüfbare und selbstreparierende Code-Generierung, die für die präzise Transformation restriktiver SAP AVC-Constraint-Netzwerke unerlässlich ist.

2.3.2 Kollaborative Agenten-Muster

Nachdem im vorangegangenen Abschnitt die kognitive Funktionsweise und Anatomie einzelner KI-Agenten definiert wurde, befasst sich dieser Abschnitt mit der Orchestrierung mehrerer Agenten. Das Ziel *kollaborativer Agenten-Muster* ist es, die in Kapitel 2.2.2 beschriebenen Limitationen monolithischer Sprachmodelle – wie den Kontextverlust bei langen Logikketten und das Fehlen systemweiter Validierung – durch arbeitsteilige Architekturen gezielt auszumerzen. In der aktuellen Forschung haben sich hierfür verschiedene methodische Paradigmen etabliert.

Rollenspezialisierung und Dehalluzination

Eine der effektivsten Methoden zur Steigerung der Codequalität ist die Zuweisung harter, voneinander abgegrenzter Expertenrollen (wie beispielsweise Programmierer, Architekt und Tester), die sich in ihrer Zusammenarbeit an bewährten Vorgehensmodellen wie dem Wasserfallprinzip orientieren. Wie Qian et al. (2024) in ihrem *ChatDev*-Framework demonstrieren, ermöglicht diese Arbeitsteilung eine strukturierte Problemlösung, die monolithischen Ansätzen deutlich überlegen ist. Ein zentrales Konzept zur Fehlervermeidung ist dabei die *Communicative Dehallucination* (kommunikative Dehalluzination):

Anstatt bei unklaren Anforderungen fehlende Parameter oder Logiken blind zu erfinden (zu halluzinieren), werden Agenten so instruiert, dass sie proaktiv beim planenden Agenten nachfragen und detailliertere Spezifikationen einfordern, bevor Quellcode generiert wird.

Inception Prompting und System-Leitplanken

Um sicherzustellen, dass Agenten ihre zugewiesenen Rollen strikt beibehalten und zielgerichtet interagieren, bedarf es klarer Leitplanken. Li et al. (2023) führen hierfür im *CAMEL*-Framework das Konzept des *Inception Promptings* ein. Dabei werden Agenten durch asymmetrische System-Prompts zu Beginn der Konversation in eine feste Rolle gezwungen und mit strikten Verhaltensregeln ausgestattet. Um systemimmanente Gefahren wie das *Role Flipping* (den ungewollten Rollentausch zwischen Instrukteur und Assistent) oder sinnlose Kommunikations-Endlosschleifen zu verhindern, implementiert das System exakte Kommunikationsprotokolle und dedizierte Abbruch-Tokens (*Termination Tokens*).

Werkzeugnutzung und Code-Ausführung

Kollaboration in Multi-Agenten-Systemen beschränkt sich nicht ausschließlich auf den Austausch natürlicher Sprache, sondern umfasst auch die Interaktion mit externen Werkzeugen (*Tool Use*) und Laufzeitumgebungen. Das *AutoGen*-Framework von Wu et al. (2024) etabliert hierfür das Paradigma des *Conversation Programming*, bei dem der Kontrollfluss der Anwendung direkt durch den Agenten-Dialog gesteuert wird. Eine zentrale Rolle nehmen dabei sogenannte Proxy-Agenten ein. Deren einzige Aufgabe ist es, den von generierenden LLM-Agenten geschriebenen Quellcode auszuführen und im Falle von Syntax- oder Laufzeitfehlern die rohen Fehlermeldungen in den Chat zurückzuspiegeln. Dadurch entsteht eine unverzichtbare Brücke zwischen Textgenerierung und empirischer Validierung.

Iterative Fehlerkorrektur (Self-Refinement)

Die zielgerichtete Reaktion auf solche durch Proxy-Agenten aufgeworfenen Fehler erfordert strukturierte Kognitionsmechanismen. Shinn et al. (2023) beschreiben in ihrem *Reflexion*-Framework den Prozess der iterativen Fehlerkorrektur durch *Self-Refinement*. Meldet die Ausführungsumgebung einen Fehler, rät das Sprachmodell nicht blind auf eine neue Lösung. Stattdessen nutzt der Agent ein episodisches Gedächtnis, um den aufgetretenen Fehler verbal zu analysieren und zu reflektieren. Durch diesen „semantischen Gra-

dienten“ leitet der Agent eine konkrete Lösungsstrategie aus dem Fehler ab, speichert diese und passt den Code im nächsten iterativen Versuch präzise an.

Standard Operating Procedures und das Fließband-Paradigma

Die Synthese all dieser Muster führt zu hochkomplexen, skalierbaren Multi-Agenten-Systemen, die traditionelle Monolithen deklassieren. Den umfassenden empirischen Beleg hierfür liefert das *MetaGPT*-Framework von Hong et al. (2024). Die Architektur simuliert ein softwareentwickelndes Unternehmen als Fließband-System (*Assembly Line Paradigm*), das seine Agenten zur Einhaltung strenger menschlicher Standardarbeitsanweisungen (*Standard Operating Procedures, SOPs*) zwingt. Eine entscheidende Neuerung ist hier der strukturierte Dokumentenaustausch: Anstatt frei miteinander zu chatten, kommunizieren die Agenten über formalisierte Spezifikationen und Design-Dokumente. Die Studie beweist, dass diese strikt orchestrierte Architektur kaskadierende Halluzinationen stoppt und Monolithen in sämtlichen Benchmarks zur Code-Generierung signifikant schlägt.

2.3.3 Entwicklungs-Frameworks für MAS

Um die theoretischen Konzepte der kognitiven Anatomie (Kapitel 2.3.1) und der kollaborativen Muster (Kapitel 2.3.2) informationstechnisch umzusetzen, greift die moderne Softwareentwicklung auf spezialisierte Agenten-Frameworks zurück. Diese Bibliotheken abstrahieren die grundlegende Komplexität der Modell-Orchestrierung und stellen die softwaretechnische Infrastruktur (wie API-Anbindungen, Kontext-Fenster-Management und Logging) bereit.

Dass sich primär drei Frameworks etabliert haben, welche den wissenschaftlichen Diskurs sowie die industrielle Praxis maßgeblich prägen, lässt sich durch aktuelle quantitative Forschung belegen. In der ersten großangelegten empirischen Studie zur Evolution von Open-Source-Multi-Agenten-Systemen analysieren Liu et al. (2025) über 42.000 Commits führender Repositories. Die Autoren weisen anhand von GitHub-Metriken empirisch nach, dass insbesondere *LangChain* (als Basis-Ökosystem), *AutoGen* und *CrewAI* mit zehntausenden Entwickler-Interaktionen den Markt anführen und das rasanten Wachstum dieser Technologie seit 2023 treiben. Diese drei dominanten Plattformen unterscheiden sich in ihrer Architekturphilosophie wie folgt:

- **LangGraph:** Entwickelt als Erweiterung des populären *LangChain*-Ökosystems, modelliert dieses Framework Multi-Agenten-Systeme als zustandsbehaftete, zyklische Graphen. Jeder Agent oder jedes Werkzeug repräsentiert einen Knoten (*Node*), während die Kommunikationspfade

als Kanten (*Edges*) definiert werden (Chase, 2024). Es bietet maximale Flexibilität für komplexe, dynamische Kontrollflüsse, erfordert jedoch einen sehr hohen manuellen Programmieraufwand bei der Definition der Zustandsübergänge.

- **AutoGen:** Das von Microsoft entwickelte Framework stellt das Paradigma des „Conversation Programming“ in den Mittelpunkt. Agenten sind hier primär als dialogfähige Entitäten konzipiert, die Aufgaben lösen, indem sie direkt miteinander chatten. AutoGen zeichnet sich laut den Entwicklern durch die native Integration von *Proxy-Agenten* zur sicheren Code-Ausführung aus, bietet jedoch weniger strukturelle Leitplanken für streng prozedurale Abläufe (Wu et al., 2024).
- **CrewAI:** Dieses Framework wählt einen rollenbasierten Top-Down-Ansatz und ist architektonisch stark an das Fließband-Paradigma von MetaGPT angelehnt. Eine Entität (die *Crew*) orchestriert definierte Agenten, die als Mitglieder einer Hierarchie agieren und spezifische, sequentielle Aufgaben (*Tasks*) abarbeiten. Es fokussiert sich auf strikte Rollenverteilungen, Delegation und Standardarbeitsanweisungen (Liu et al., 2025).

Mapping von Theorie und Framework-Praxis

Die Entscheidung für ein solches Framework verschiebt die Aufgaben des Systemarchitekten. Die von Wang et al. (2024) definierte kognitive Kern-Anatomie ist in diesen Frameworks in der Regel als abstrahierte Code-Basis (*Out-of-the-Box*) verankert. So wird das Kurz- und Langzeitgedächtnis (*Memory*) oftmals automatisiert über integrierte Vektordatenbanken verwaltet. Auch das entscheidende *ReAct*-Paradigma (Yao et al., 2022) – mithin die Schleife aus Denken, Werkzeugnutzung und Beobachtung – läuft als nativer Hintergrundprozess ab, sobald einem Agenten ein Tool zugewiesen wird.

Obgleich diese Frameworks die informationstechnische Infrastruktur bereitstellen, abstrahieren sie lediglich universelle Prozesse und besitzen keinerlei domänenspezifisches Wissen über proprietäre SAP-Architekturen. Die maßgebliche Implementierungsleistung verlagert sich somit zwingend auf die manuelle Domänenspezialisierung. Unabhängig vom gewählten Framework verbleiben daher zwei Kernaufgaben in der Hand des Entwicklers:

1. **Systemdesign und Prompt-Engineering:** Der Entwickler muss evaluieren, welche der in Kapitel 2.3.2 beschriebenen theoretischen Konzepte am besten zur vorliegenden Problemstellung passen, und das Framework damit „befüllen“. Dies umfasst das harte Kodieren des

Profilings (Rollen und Identitäten), der Standardarbeitsanweisungen (SOPs) sowie der Delegationsregeln.

2. **Custom Tools (Werkzeug-Entwicklung):** Während das Framework die Logik des *Tool-Aufrufs* an sich abstrahiert, existieren für proprietäre Domänen – wie die SAP Variantenkonfiguration – keine vorgefertigten Werkzeuge. Die informationstechnische Brücke zwischen dem Agenten und der Zielumgebung (beispielsweise ein *Mock-Compiler* zur Syntax-Validierung von Constraint-Netzwerken) muss vollständig manuell entwickelt und als funktionale Schnittstelle in das Framework injiziert werden.

Mit den in diesem Kapitel erläuterten Konzepten – von den restriktiven Constraint-Netzwerken der SAP-Variantenkonfiguration über die Limitationen monolithischer Sprachmodelle bis hin zu den kollaborativen Architekturmustern moderner Agenten-Frameworks – sind nun alle wesentlichen technologischen Grundlagen für das tiefe Verständnis dieser Arbeit geschaffen. Im methodischen Gesamtkontext der Masterarbeit bildet diese fundierte Literaturanalyse die erste tragende Säule einer methodischen Triangulation. Die hier gewonnenen wissenschaftlichen Erkenntnisse dienen als theoretisches Alibi und Fundament, auf dem die nachfolgenden praktischen und architektonischen Entscheidungen aufbauen, um schließlich die eigens konzipierte Multi-Agenten-Migrationsarchitektur wissenschaftlich fundiert herzuleiten und zu begründen.

Kapitel 3

Related Work

Die Automatisierung komplexer Software-Migrationen erfordert ein tiefgreifendes Verständnis sowohl der proprietären Zieldomäne als auch der neuesten informationstechnischen Möglichkeiten. Da die wissenschaftliche Forschungslage an der direkten Schnittstelle zwischen proprietärer SAP-Migration und generativer Künstlicher Intelligenz bislang äußerst dünn besetzt ist, ordnet dieses Kapitel die vorliegende Arbeit anhand hochaktueller Publikationen aus angrenzenden Disziplinen in den Stand der Technik ein. Hierzu werden zunächst die spezifischen prozessualen Hürden bei der Transformation von SAP-Konfigurationsmodellen beleuchtet, um die Limitierungen aktueller Standardwerkzeuge aufzuzeigen. Daran anknüpfend wird der Einsatz von Large Language Models (LLMs) für die Code-Migration diskutiert, wobei insbesondere die empirisch belegten Grenzen monolithischer Ansätze bei strikten Architekturvorgaben herausgearbeitet werden. Abschließend wird der aktuelle State of the Art zu Multi-Agenten-Systemen (MAS) vorgestellt, um die methodische Forschungslücke für die semantische Migration von proprietärer Constraint-Logik logisch herzuleiten.

Die Migration von etablierten ERP-Systemen auf SAP S/4HANA zwingt Unternehmen zur Überführung ihrer historisch gewachsenen Produktmodelle von der klassischen Variantenkonfiguration (LO-VC) in die Advanced Variant Configuration (AVC). Matilainen (2024, S. 31) verdeutlicht in seiner Untersuchung zu S/4HANA-Produktdatenstrukturen, dass dieser Systemwechsel eine enorme Komplexität birgt, da die Anzahl der möglichen Konfigurationen mit der Menge der Merkmale und Optionen exponentiell ansteigt. Um diese Variantenvielfalt im neuen System technisch beherrschbar zu machen, ist eine präzise Restrukturierung der Datenmodelle unumgänglich.

Ein kritischer Erfolgsfaktor der Migration ist dabei die vorgelagerte Datenbereinigung. Wie Matilainen (2024, S. 52, S. 84) aufzeigt, müssen ungenutzte historische Datenelemente (Legacy Data) vor der Systemumstellung zwin-

gend identifiziert und entfernt werden, um Strukturen zu vereinfachen und Prozesse im Zielsystem nicht zu belasten. Obgleich SAP für diesen Übergang Standardwerkzeuge wie Transition Workspaces oder das Migration Cockpit zur Verfügung stellt, liegt deren Fokus primär auf der Massendatenübernahme und technischen Synchronisation. Wie jedoch das im Rahmen dieser Arbeit durchgeführte Experteninterview (siehe Kapitel 3) belegt, existiert bei der logischen Transformation eine signifikante Lücke: Die Standardwerkzeuge arbeiten weitestgehend deterministisch und sind nicht in der Lage, die notwendige semantische Interpretation von prozeduralem Beziehungswissen in eine rein deklarative AVC-Logik autonom zu leisten. Diese inhaltliche Restrukturierung sowie die Bereinigung kognitiver Altlasten im Code verbleiben somit als manueller, ressourcenintensiver Flaschenhals, für den die aktuelle industrielle Praxis keine automatisierten Lösungen bereithält.

Die rasanten Fortschritte im Bereich der Large Language Models (LLMs) haben die Möglichkeiten der automatisierten Code-Generierung und -Transformation grundlegend erweitert (Karabiyik, 2025). Dennoch belegen aktuelle Forschungsarbeiten, dass der direkte Einsatz von LLMs für die Migration komplexer Altsysteme – oft als „Single-Prompt-Ansatz“ oder „Monolithic Prompting“ bezeichnet – in realen Produktionsumgebungen kaum praktikable Ergebnisse liefert. Die Ursache hierfür liegt primär in der Unfähigkeit monolithischer Ansätze, spezifische Architekturvorgaben und interne Framework-Abhängigkeiten zu berücksichtigen. Moti et al. (2026) demonstrieren in ihrer Untersuchung zum Framework LegacyTranslate, dass naive LLM-Übersetzungen bei der Migration industrieller Codebasen eine Kompilierrate von 0 % erreichen können. Während der generierte Code zwar syntaktisch korrekt erscheint, scheitert er an der fehlenden Integration notwendiger interner Schnittstellen (APIs) und domänenspezifischer Logik (Moti et al., 2026). Ähnliche Defizite dokumentieren Xu et al. (2025) im Kontext von MANTRA: Während spezialisierte Systeme hohe Erfolgsquoten erzielen, erreichen monolithische Basismodelle bei komplexen strukturellen Änderungen lediglich eine Erfolgsquote von 8,7 %.

Darüber hinaus identifizieren Karabiyik (2025) und Oueslati et al. (2026) konzeptionelle Schwächen in der Kontrollierbarkeit solcher „One-Shot“-Ansätze. Ohne eine Aufteilung in modulare Arbeitsschritte bleibt der Transformationsprozess eine intransparente „Blackbox“, die keine funktionalen Garantien bietet und bei längeren Interaktionen zu Halluzinationen neigt (Karabiyik, 2025; Oueslati et al., 2026). Um diese Unzulänglichkeiten zu überwinden, rückt die aktuelle Forschung zunehmend Multi-Agenten-Systeme (MAS) in den Fokus. Diese basieren auf dem Prinzip der verteilten Kognition, bei der der Transformationsprozess in logisch abgegrenzte Teilaufgaben zerlegt wird, die von kooperierenden, spezialisierten Agenten autonom bearbeitet werden.

Dabei belegen aktuelle Arbeiten zunächst im Bereich des automatisierten Software-Refactorings – also der strukturellen Optimierung innerhalb derselben Programmiersprache –, die prozessuale Überlegenheit modularer Architekturen. Das Framework RefactorGPT überführt den Refactoring-Prozess durch eine sequentielle Orchestrierung in einen kontrollierbaren Workflow (Karabiyik, 2025). Die methodische Stärke dieser Rollenverteilung wird durch das Framework RefAgent bestätigt: Ein System aus spezialisierten Agenten für Planung, Ausführung und iterative Fehlerbehebung ist in der Lage, die Kompiliererfolgsrate im Vergleich zu Single-Agent-Ansätzen signifikant zu steigern und Halluzinationen zu reduzieren (Oueslati et al., 2026). Ein zentrales Merkmal dieser Prozess-Sicherheit ist die Integration autonomer Feedback-Schleifen. Das System MANTRA nutzt hierfür einen „Repair Agent“, der mittels „Verbal Reinforcement Learning“ Compiler-Fehler korrigiert, wodurch die Erfolgsquote bei komplexen Transformationen auf 82,8 % gesteigert werden konnte (Xu et al., 2025).

Während diese Refactoring-Ansätze die grundsätzliche Effizienz der verteilten Agenten-Kollaboration validieren, demonstriert das Projekt LegacyTranslate (Moti et al., 2026), dass sich diese Architektur auch auf die ungleich komplexere Herausforderung harter Cross-Language-Migrationen anwenden lässt. Im Gegensatz zur Umstrukturierung innerhalb einer Sprache erfordert die Migration von PL/SQL zu Java einen Paradigmenwechsel, der dem Übergang von LO-VC zu AVC ähnelt. LegacyTranslate verdeutlicht hierbei die Notwendigkeit des „API Grounding“, um den Zielcode aktiv an interne Architekturvorgaben anzupassen. Ähnlich wie dieses Grounding sicherstellt, dass interne Bibliotheken korrekt eingebunden werden, muss ein Agenten-System im SAP-Umfeld sicherstellen, dass die Transformation strikt den „Clean Core“-Richtlinien folgt – etwa durch die gezielte Vermeidung proprietärer Z-Funktionsbausteine zugunsten des SAP-Standards.

Trotz der empirisch nachgewiesenen Überlegenheit von MAS bei der Code-Übersetzung offenbart die aktuelle Literatur eine signifikante Lücke hinsichtlich proprietärer ERP-Ökosysteme. Während etablierte Frameworks wie MANTRA oder LegacyTranslate primär auf imperative oder objektorientierte Standardsprachen (wie Java oder PL/SQL) fokussiert sind, fehlt bislang die Anwendung kollaborativer KI-Architekturen auf die domänenspezifische Constraint-Logik der SAP. Es ist wissenschaftlich bisher nicht belegt, inwiefern Multi-Agenten-Systeme in der Lage sind, historisch gewachsene Regelwerke semantisch in ein deklaratives Constraint Satisfaction Problem (CSP) zu übersetzen. Bisherige MAS-Ansätze bieten keine architektonische Antwort auf dieses fachliche Umdenken, das LO-VC-Vorbedingungen in ein mathematisches Lösungsnetzwerk überführt.

Genau an dieser methodischen Schnittstelle setzt die vorliegende Arbeit an.

Sie schließt die identifizierte Forschungslücke, indem sie die Konzepte arbeitsteiliger Agenten-Architekturen auf die spezifischen Herausforderungen der SAP-Variantenkonfiguration überträgt. Durch die Konzeption und Evaluierung eines spezialisierten Multi-Agenten-Systems zur semantischen Migration von LO-VC nach AVC wird ein Lösungsansatz entwickelt, der den aktuellen manuellen Flaschenhals der Logik-Transformation systematisch adressiert und das Systemverhalten aktiv an die moderne, deklarative Zielarchitektur anpasst.

Kapitel 4

Experteninterview

In diesem Kapitel wird die Durchführung und Auswertung der Experteninterviews beschrieben. Die gewonnenen Erkenntnisse dienen als qualitative Basis für die Anforderungen an die spätere Systemumgebung.

4.1 Zielsetzung und Erkenntnisinteresse

Die Relevanz sowie die Kritikalität der Migration von LOVC zu AVC für Unternehmen wurden bereits im vorangehenden Kapitel dargelegt. Für eine KI-gestützte Automatisierung dieses Prozesses mittels eines Multi-Agenten-Systems ist die Kenntnis der theoretischen Differenzen zwischen LOVC und AVC allein unzureichend. Spezifische, historisch gewachsene Problemstellungen in der Entwicklungspraxis lassen sich nicht rein analytisch aus Systemdokumentationen ableiten und weisen oft eine hohe Kontextabhängigkeit auf. Zudem mangelt es an quantitativen Daten bezüglich des zeitlichen Migrationsaufwands, was die Validierung der Relevanz und Notwendigkeit einer Automatisierung erschwert.

Folglich ist die Durchführung von Experteninterviews zur Beantwortung der ersten Forschungsfrage essenziell. Dieses methodische Vorgehen dient der Identifikation impliziter Problemstellungen im msg-Kontext. Daraus werden sowohl quantitative Metriken für die Definition einer menschlichen Baseline und die spätere Evaluation des Modells generiert als auch funktionale Anforderungen an einen KI-basierten Migrationsassistenten abgeleitet.

4.2 Methodisches Forschungsdesign

Als methodisches Forschungsdesign zur Durchführung der Experteninterviews wird der semi-strukturierte Ansatz gewählt. Aufgrund der hohen Komplexität

der Migration von LOVC zu AVC, welche unter anderem durch menschliches Verhalten und undokumentiertes Wissen geprägt ist, bedarf es zur fundierten Durchdringung der Problemstellung neben quantitativen Methoden zwingend qualitativer Forschungsansätze. Diese methodische Notwendigkeit wird durch die einschlägige Grundlagenliteratur gestützt. (Seaman, 1999)

Die Wahl des semi-strukturierten Formats erweist sich hierbei als zielführend. Rein unstrukturierte Interviews gewähren den Befragten oftmals ein Übermaß an Spielraum, sind ressourcenintensiv und bergen das Risiko, dass essenzielle Themenkomplexe unberücksichtigt bleiben. Demgegenüber limitiert ein streng strukturiertes Vorgehen den Raum für unerwartete qualitative Erkenntnisse. (Seaman, 1999)

Da die Zielsetzung der Datenerhebung sowohl die Akquise antizipierter als auch unerwarteter Informationen umfasst, stellt das semi-strukturierte Interview das optimale Instrumentarium dar. Das Erhebungsdesign setzt sich folglich aus einer Kombination offener und spezifischer Fragen zusammen. Diese Konzeption zielt darauf ab, einerseits vorhersehbare Daten zu generieren – wie etwa zeitliche Metriken zur Etablierung einer menschlichen Baseline –, und andererseits unerwartete Erkenntnisse zu gewinnen. Letztere sind beispielsweise für die praxisnahe Anforderungsdefinition an ein KI-basiertes Migrationssystem von hoher Relevanz.

Hinsichtlich der Vorbedingungen an die befragende Person sowie an die Durchführung der Interviews gelten spezifische Prämissen. Während in diversen sozialwissenschaftlichen Disziplinen ein geringes Vorwissen der interviewenden Person oft ausreichend ist, postulieren Hove & Anda (2005) für den Bereich der Softwareentwicklung die Notwendigkeit eines tiefgreifenden technischen Vorverständnisses. Zur Gewährleistung einer lückenlosen und korrekten Datenerfassung ist zudem die vollständige Audioaufzeichnung und anschließende Transkription der Interviews unerlässlich. (Hove & Anda, 2005)

Die Auswertung des Interviewtranskripts erfolgte durch einen systematischen Mixed-Methods-Ansatz, der Methoden der qualitativen und quantitativen Datenanalyse kombiniert. Um eine lückenlose Beweiskette ('Chain of Evidence') gemäß Runeson und Höst (2009) sicherzustellen, gliederte sich der Codierungsprozess in zwei Phasen: Zunächst wurde in Anlehnung an die strukturierende Inhaltsanalyse nach Mayring (2014) eine deduktive Kategorienanwendung durchgeführt. Hierbei wurden im Vorhinein definierte Codes, welche direkt aus den drei Forschungsfragen abgeleitet wurden, auf das Textmaterial angewendet, um dieses theoriegeleitet zu codieren.

Um gleichzeitig eine methodische Offenheit für unvorhergesehene praxisnahe Schmerzpunkte bei der Migration zu gewährleisten, wurde dieser Schritt durch eine induktive Kategorienbildung (Mayring (2014)) ergänzt, bei der ergänzende Codes iterativ am empirischen Material entwickelt wurden. (siehe

Anhang 4.5.4). Daran anschließend wurden aus den codierten Textstellen Field Memos generiert, welche die Kernaussagen der Befragung zusammenfassen und als Hypothesen für die in Kapitel 3.5. beschriebenen Anforderungen an die Systemarchitektur dienen. (Seaman, 1999)

Ziel dieser Auswertung war eine duale Erkenntnisgewinnung: Einerseits wurden durch gezieltes quantitatives Coding (Seaman (1999)) harte Metriken zum zeitlichen und manuellen Aufwand extrahiert, welche als menschliche Baseline für die spätere Modellevaluation des Multi-Agenten-Systems dienen. Andererseits wurden aus den identifizierten kognitiven und prozessualen Hürden funktionale Anforderungen an die zukünftige KI-Architektur abgeleitet. Diese Anforderungen stellen jedoch bewusst noch nicht die finale Systemarchitektur dar. Gemäß dem Prinzip der Methodentriangulation (Runeson und Höst (2009)) bilden die Erkenntnisse des Experteninterviews lediglich eine von drei Säulen, welche im weiteren Verlauf der Arbeit mit den Ergebnissen des praktischen Selbstversuchs (Kapitel X) und der theoretischen Grundlagenanalyse (Kapitel Y) synthetisiert werden, um die finale, valide Agenten-Architektur zu konstruieren.

Ein zentrales Qualitätsmerkmal qualitativer Fallstudien im Software Engineering stellt die Aufrechterhaltung einer lückenlosen Beweiskette (Chain of Evidence") dar. Im Kontext dieser Arbeit impliziert dies die transparente Ableitung der Notwendigkeit jedes einzelnen KI-Agenten aus den Rohdaten. Die methodische Nachvollziehbarkeit wird hierbei über den gesamten Prozess – von der Audioaufzeichnung über das codierte Transkript und die daraus resultierenden Field-Memos (Kernaussagen) bis hin zu den finalen funktionalen Anforderungen an die Systemarchitektur – gewährleistet. (Runeson & Höst, 2009)

4.3 Datenerhebung und Auswertung

Das Experteninterview wurde am 17.03.2026 mit einem erfahrenen Product Owner und Softwareentwickler der msg durchgeführt. Die Fachexpertise des Interviewpartners umfasst eine zwölfjährige Tätigkeit als Maschinenbauingenieur sowie eine mehr als sechsjährige Spezialisierung auf dem Gebiet der Variantenkonfiguration. Seit knapp vier Jahren liegt sein Tätigkeitsschwerpunkt auf der Betreuung von Kundenprojekten zur Variantenkonfiguration im msg-Kontext. Die Gesprächsdauer belief sich auf rund 45 Minuten. Die Befragung erfolgte durch den Autor dieser Arbeit mit solidem technischem Vorwissen in den Bereichen LOVC und AVC. Als Erhebungsinstrument diente ein vorab definierter Interviewleitfaden. Dieser umfasste offene Fragen zur Akquise unerwarteter Erkenntnisse sowie spezifische Fragestellungen zum

gezielten Informationsgewinn und der Erhebung von quantitativen Metriken. Letztere dienen der Beantwortung der ersten Forschungsfrage sowie der späteren Modellevaluation.

Mit Einverständnis des Experten erfolgte eine vollständige Aufzeichnung sowie automatische Transkription des Gesprächs über die integrierte Funktion von MS Teams. Zur Gewährleistung der Vertraulichkeit wurde das Transkript im Anschluss manuell anonymisiert. Zur Optimierung der Lesbarkeit fand daraufhin eine KI-gestützte Glättung des Textes unter strikter Wahrung der inhaltlichen Integrität statt. Eine finale manuelle Überprüfung des Resultats stellte sicher, dass durch die KI-Bearbeitung keine inhaltlichen Verzerrungen eingeführt wurden.

Die anschließende Datenauswertung erfolgte mittels des in Kapitel 3.2 beschriebenen Codierungsverfahrens. Die initiale Codeliste wurde deduktiv aus den drei Kernfragen des Interviewleitfadens abgeleitet. Zur Gewährleistung einer lückenlosen Beweiskette von der Datenerhebung bis zur Systemarchitektur erfolgte eine Gliederung der Codes in drei Hauptkategorien: 1. Erfassung der manuellen Prozessschritte, 2. Quantifizierung des zeitlichen Aufwands und Identifikation von Engpässen sowie 3. systematische Erfassung kognitiver Hürden und typischer menschlicher Fehlerquellen.

Darauf aufbauend wurde das Transkript in einem iterativen Prozess durch induktive Code-Generierung erweitert, um unerwartete Erkenntnisse strukturiert zu erfassen. Den Abschluss des Codierungsprozesses bildete die inhaltliche Gruppierung der Codes zur Extraktion der Kernaussagen. Aus diesen Ergebnissen wurden schließlich belastbare funktionale Anforderungen an das Multi-Agenten-System abgeleitet sowie die zeitlichen Metriken zur Definition der menschlichen Baseline generiert.

4.4 Ergebnisse der Befragung

Die nachfolgende Darstellung fasst die zentralen Erkenntnisse der qualitativen Inhaltsanalyse zusammen, welche durch die Synthese der Field Memos in thematische Schwerpunkte gegliedert wurden. Diese deskriptiven Ergebnisse bilden den empirischen Ist-Zustand des Migrationsprozesses ab und dienen als Grundlage für die spätere Anforderungsanalyse und die Definition der menschlichen Baseline.

4.4.1 Kognitive Altlasten und historischer Code

Die Auswertung der Interviewdaten verdeutlicht, dass historisch gewachsene LOVC-Modelle durch eine hohe Dichte an ungenutzten Altlasten charakte-

risiert sind. Merkmale, Prozeduren und Beziehungswissen verbleiben oft im System, ohne im aktuellen Modellierungskontext eine funktionale Relevanz zu besitzen. Zudem führen über Jahre stetig anwachsende Werteräume zu einer erhöhten Komplexität. Für den Migrationsprozess bedeutet dies, dass eine unreflektierte 1:1-Konvertierung in den Advanced Variant Configurator (AVC) aufgrund dieser behindernden Altlasten in der Praxis unzureichend ist. Für den Entwickler resultiert daraus eine erhebliche kognitive Belastung, da eine zeitintensive manuelle Analyse zur Trennung von aktiver Logik und „totem Code“ zwingend erforderlich ist, bevor die eigentliche syntaktische Transformation beginnen kann.

4.4.2 Paradigmenwechsel und syntaktisches Umdenken

Über die rein syntaktische Ebene hinaus zeigt die Befragung einen fundamentalen Paradigmenwechsel in der Modellierungstechnik auf. Dieser wird maßgeblich durch die „Clean Core“-Strategie der SAP getrieben, wodurch Eigenentwicklungen wie Z-Functions nicht mehr unterstützt werden. Da sich das Systemverhalten im AVC selbst bei identischer Syntax massiv ändern kann – etwa durch den Zwang zu klassifizierten Merkmalen oder die globale Wirkung von Constraints – führt eine bloße Übernahme alter Logiken häufig zu abweichenden Konfigurationsergebnissen oder Performance-Einbußen. Der Migrationsprozess erfordert daher ein aktives Umdenken: Entwickler müssen die ursprüngliche Intention des Legacy-Codes in Gänze verstehen und diese semantisch mit den neuen Bordmitteln des AVC abbilden.

4.4.3 Fragmentierung manueller Prozessschritte

Trotz der Existenz von Standard-Tools zur Massenanlage von Objekten bleibt der Migrationsprozess in weiten Teilen fragmentiert und durch manuelle Arbeitsschritte geprägt. Während Automatisierungen die Anlage von Basisdaten übernehmen können, verbleibt die komplexe intellektuelle Durchdringung der Logik beim Entwickler. Dieser muss Vorbedingungen manuell auswerten, in tabellenbasierte Strukturen überführen und abschließend auf Konsistenz prüfen. Dieser Workflow erzwingt häufig Medienbrüche und degradiert den Experten zu einer „manuellen Übersetzungsmaschine“, was die Fehleranfälligkeit erhöht und den Prozess verlangsamt.

4.4.4 Limitierungen bestehender Standard-Tools

Die Auswertung zeigt, dass bestehende Standardlösungen wie das „SAP Migration Cockpit“ primär die rein technischen Datenübernahmen (wie die Mas-

senanlage von Objekten) abdecken. Bei der komplexen Logik-Transformation entstehen jedoch funktionale Lücken. Der Experte äußert den Bedarf nach einer prozessualen Unterstützung auf einer „beratenden Flugebene“, welche Zusammenhänge aufzeigt und Optimierungspotenziale identifiziert. Es mangelt im aktuellen Ist-Zustand an Werkzeugen zur automatisierten Kommentierung von historischem Code, zur tiefgehenden Analyse von Z-Functions sowie an proaktiven Ratschlägen zur Modellstrukturierung. Eine rein statische Code-Konvertierung erweist sich für den Gesamtprozess somit als unzureichend.

4.4.5 Manueller Aufwand und Fehleranfälligkeit im Testprozess

Ein signifikanter Flaschenhals wurde im Bereich der Qualitätssicherung identifiziert. Das Testen migrierter Modelle erfolgt gegenwärtig weitgehend manuell, da bestehende Testtools oft nicht in der Lage sind, logische Veränderungen zwischen Alt- und Neusystem korrekt zu interpretieren. Dies führt zu einem massiven Aufwand beim händischen Abgleich von Testaufträgen und birgt ein entsprechendes Potenzial für menschliche Flüchtigkeitsfehler in der abschließenden Validierungsphase.

4.4.6 Zeitliche Metriken und Identifikation von Flaschenhälsen

Zur Definition einer menschlichen Baseline wurden im Rahmen der Befragung konkrete zeitliche Metriken erhoben. Die Migration eines mittleren Modells beansprucht demnach etwa drei bis vier Personentage, wobei Extremfälle bei komplexen Strukturen bis zu mehrere Monate beanspruchen können. Als primärer zeitlicher Flaschenhals wurde die Transformation der Vorbedingungswelt identifiziert, die etwa zwei Drittel (66 %) der gesamten Arbeitszeit beansprucht. Weitere 40 % des Aufwands entfallen auf die vorbereitende Analyse und den Aufbau unterstützender Strukturen wie Excel-Tabellen. Diese quantifizierten Werte bilden die Vergleichsvariablen für die spätere Evaluierung.

Die hier dargelegten empirischen Befunde skizzieren die aktuellen prozessualen und kognitiven Hürden der Migration. Sie bilden die konzeptionelle Ausgangslage, um im folgenden Unterkapitel konkrete Implikationen und Anforderungen an die zu entwickelnde Systemarchitektur abzuleiten.

4.5 Implikationen für die Systemarchitektur

Basierend auf den empirischen Befunden der qualitativen Inhaltsanalyse lassen sich spezifische Anforderungen und konzeptionelle Leitplanken für die Gestaltung der Systemarchitektur ableiten. In diesem Kapitel werden ausschließlich jene Implikationen dargelegt, die direkt aus der Expertenbefragung hervorgehen.

4.5.1 Funktionale Anforderungen aus der Expertenperspektive

Aus den identifizierten prozessualen Hürden ergeben sich zwingende funktionale Notwendigkeiten für das Systemdesign:

- **Semantische Analyse und Code-Bereinigung:** Da historische Altlasten die Migration behindern, muss die Architektur eine Komponente zur Identifikation von ungenutzten Merkmalen und Prozeduren enthalten. Ziel ist eine Reduktion der kognitiven Last durch eine automatisierte Vorab-Bereinigung des Legacy-Codes.
- **Automatisierte Logik-Transformation:** Angesichts des zeitlichen Flaschenhalses bei der Erstellung von Tabellen und Constraints muss der Fokus auf der automatisierten Generierung dieser Strukturen liegen. Das System muss in der Lage sein, die logische Restrukturierung von Vorbedingungen zu übernehmen, um den manuellen Aufwand in diesem Bereich zu minimieren.
- **Konsistenzprüfung im Testprozess:** Um die Fehleranfälligkeit bei der Validierung zu senken, wird eine Funktion zum Mapping alter Testkonfigurationen auf die Zielmodelle benötigt, die logische Abweichungen zwischen den Systemwelten erkennt.

4.5.2 Architektonische Paradigmen und Beratungsansatz

Der identifizierte Paradigmenwechsel in der Modellierungstechnik bedingt spezifische architektonische Eigenschaften:

- **Interaktive Assistenz (Consulting-Ansatz):** Das System darf nicht als rein deterministischer Konverter agieren. Gefordert ist eine interaktive Ebene, die Design-Entscheidungen begründet und dem Nutzer beratend zur Seite steht, um den Kontext der Transformation transparent zu machen.

- **Einhaltung von Modellierungsrichtlinien (Clean Core):** Die Architektur muss aktuelle SAP-Vorgaben wie die Clean-Core-Strategie und Performance-Best-Practices als Wissensbasis integrieren. Transformationen müssen proaktiv auf diese Zielarchitektur hin optimiert werden, statt lediglich die Quellsyntax abzubilden.

4.5.3 Konzeptionelle Notwendigkeit einer Multi-Agenten-Struktur

Die Heterogenität der Anforderungen – von der Analyse komplexer Z-Functions bis hin zur Validierung von Test-Sets – legt eine Verteilung der Aufgaben auf spezialisierte Rollen nahe. Ein monolithischer Ansatz erscheint unzureichend, um die benötigte Tiefe in den Bereichen Analyse, Beratung, Synthese und Test gleichzeitig abzudecken. Daraus ergibt sich die Notwendigkeit einer Multi-Agenten-Architektur, in der spezialisierte Agenten (Analyst, Syntaktiker, Tester und Consultant) kollaborativ zusammenarbeiten.

4.5.4 Quantitative Zielvorgaben für die Systemvalidierung

Die erhobenen Zeitmetriken definieren die Erfolgskriterien für die spätere Evaluierung der Architektur. Das System muss gegen die menschliche Baseline von drei bis vier Tagen pro Modell validiert werden. Insbesondere muss nachgewiesen werden, dass der primäre Flaschenhals der Vorbedingungs-Transformation (66 % des Gesamtaufwands) sowie die vorbereitende Analysephase (40 % des Aufwands) durch die automatisierte Unterstützung signifikant reduziert werden können.

Die hier dargelegten interviewbasierten Implikationen bilden zusammen mit den Erkenntnissen aus dem Selbstexperiment und der theoretischen Analyse die vollständige Anforderungsbasis für den anschließenden Systementwurf in Kapitel 4.

Literatur

- Blumöhr, U., Kölbl, A., Neuhaus, M., & Ukalovic, M. (2023). *Advanced Variant Configuration in SAP S/4HANA*. Rheinwerk Publishing. Verfügbar 6. Mai 2026 unter <https://katalog.ub.uni-heidelberg.de/titel/69115224>
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., & Askell, A. (2020). Language Models Are Few-Shot Learners. *Advances in neural information processing systems*, 33, 1877–1901. Verfügbar 16. Mai 2026 unter https://proceedings.neurips.cc/paper_files/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html?utm_source=transaction&utm_medium=email&utm_campaign=linkedin_newsletter
- Chase, H. (2024). *Langchain*. <https://github.com/langchain-ai/langchain>
- Chen, M., Tworek, J., Jun, H., Yuan, Q., Pinto, H. P. d. O., Kaplan, J., Edwards, H., Burda, Y., Joseph, N., Brockman, G., Ray, A., Puri, R., Krueger, G., Petrov, M., Khlaaf, H., Sastry, G., Mishkin, P., Chan, B., Gray, S., ... Zaremba, W. (2021, 14. Juli). *Evaluating Large Language Models Trained on Code*. arXiv: 2107.03374 [cs]. <https://doi.org/10.48550/arXiv.2107.03374>
- Hong, S., Zhuge, M., Chen, J., Zheng, X., Cheng, Y., Wang, J., Zhang, C., Yau, S., Lin, Z., & Zhou, L. (2024). MetaGPT: Meta Programming for a Multi-Agent Collaborative Framework. *International Conference on Learning Representations, 2024*, 23247–23275. Verfügbar 20. Mai 2026 unter https://proceedings.iclr.cc/paper_files/paper/2024/hash/6507b115562bb0a305f1958ccc87355a-Abstract-Conference.html
- Hove, S. E., & Anda, B. (2005). Experiences from Conducting Semi-Structured Interviews in Empirical Software Engineering Research. *11th IEEE International Software Metrics Symposium (METRICS'05)*, 10–pp. Verfügbar 31. März 2026 unter <https://ieeexplore.ieee.org/abstract/document/1509301/>
- Jimenez, C. E., Yang, J., Wettig, A., Yao, S., Pei, K., Press, O., & Narasimhan, K. (2024). Swe-Bench: Can Language Models Resolve Real-World

- Github Issues? *International Conference on Learning Representations, 2024*, 54107–54157. Verfügbar 20. Mai 2026 unter https://proceedings.iclr.cc/paper_files/paper/2024/hash/edac78c3e300629acfe6cbe9ca88fb84-Abstract-Conference.html
- Karabiyik, M. A. (2025). RefactorGPT: A ChatGPT-based Multi-Agent Framework for Automated Code Refactoring. *PeerJ Computer Science*, 11, e3257. Verfügbar 21. April 2026 unter <https://peerj.com/articles/cs-3257/>
- Li, G., Hammoud, H., Itani, H., Khizbullin, D., & Ghanem, B. (2023). Camel: Communicative Agents forMMindExploration of Large Language Model Society. *Advances in neural information processing systems*, 36, 51991–52008. Verfügbar 20. Mai 2026 unter <https://proceedings.neurips.cc/paper/2023/hash/a3621ee907def47c1b952ade25c67698-Abstract-Conference.html>
- Liu, D., Upadhyay, K., Chhetri, V., Siddique, A. B., & Farooq, U. (2025). A Large-Scale Study on the Development and Issues of Multi-Agent AI Systems. *2025 IEEE International Conference on Big Data (BigData)*, 7785–7792. Verfügbar 2. Juni 2026 unter <https://ieeexplore.ieee.org/abstract/document/11402104/>
- Matilainen, A. (2024). Change Requirements on Product Data Structures in S/4HANA Implementation. Verfügbar 21. April 2026 unter <https://osuva.uwasa.fi/items/8bf7ae52-e756-4fca-9a25-c0510c58ad34>
- Mayring, P. (2014). Qualitative Content Analysis: Theoretical Foundation, Basic Procedures and Software Solution. Verfügbar 7. April 2026 unter https://www.ssoar.info/ssoar/bitstream/handle/document/39517/ssoar-2014-mayring-Qualitative_content_analysis_theoretical_foundation.pdf
- Moti, Z., Soudani, H., & van der Kogel, J. (2026, 14. März). *LegacyTranslate: LLM-based Multi-Agent Method for Legacy Code Translation*. arXiv: 2603.14054 [cs]. <https://doi.org/10.48550/arXiv.2603.14054>
- Oueslati, K., Lamothe, M., & Khomh, F. (2026, 4. März). *RefAgent: A Multi-agent LLM-based Framework for Automatic Software Refactoring*. arXiv: 2511.03153 [cs]. <https://doi.org/10.48550/arXiv.2511.03153>
- Qian, C., Liu, W., Liu, H., Chen, N., Dang, Y., Li, J., Yang, C., Chen, W., Su, Y., & Cong, X. (2024). Chatdev: Communicative Agents for Software Development. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 15174–15186. Verfügbar 20. Mai 2026 unter <https://aclanthology.org/2024.acl-long.810/>

- Runeson, P., & Höst, M. (2009). Guidelines for conducting and reporting case study research in software engineering. *Empirical Software Engineering*, 14(2), 131–164. <https://doi.org/10.1007/s10664-008-9102-8>
- Russell, S. J. (2010). *Artificial Intelligence a Modern Approach*. Pearson Education, Inc. Verfügbar 26. Mai 2026 unter <https://scholar.alaqsa.edu.ps/9195/1/Artificial%20Intelligence%20A%20Modern%20Approach%20%283rd%20Edition%29.pdf%20%28%20PDFDrive%20%29.pdf>
- Seaman, C. B. (1999). Qualitative Methods in Empirical Studies of Software Engineering. *IEEE Transactions on software engineering*, 25(4), 557–572. Verfügbar 31. März 2026 unter <https://ieeexplore.ieee.org/abstract/document/799955/>
- Shinn, N., Cassano, F., Gopinath, A., Narasimhan, K., & Yao, S. (2023). Reflection: Language Agents with Verbal Reinforcement Learning. *Advances in neural information processing systems*, 36, 8634–8652. Verfügbar 20. Mai 2026 unter https://proceedings.neurips.cc/paper_files/paper/2023/hash/1b44b878bb782e6954cd888628510e90-Abstract-Conference.html
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in neural information processing systems*, 30. Verfügbar 16. Mai 2026 unter <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>
- Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., Zhao, W. X., Wei, Z., & Wen, J. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6), 186345. <https://doi.org/10.1007/s11704-024-40231-1>
- Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., & Liu, J. (2024). Autogen: Enabling next-Gen LLM Applications via Multi-Agent Conversations. *First Conference on Language Modeling*. Verfügbar 20. Mai 2026 unter https://openreview.net/forum?id=BAakY1hNKS&utm_source=
- Xu, Y., Lin, F., Yang, J., Tse-Hsun, Chen & Tsantalis, N. (2025, 27. März). *MANTRA: Enhancing Automated Method-Level Refactoring with Contextual RAG and Multi-Agent LLM Collaboration*. arXiv: 2503.14340 [cs]. <https://doi.org/10.48550/arXiv.2503.14340>
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2022). *React: Synergizing Reasoning and Acting in Language Models*. Verfügbar 20. Mai 2026 unter <https://arxiv.org/abs/2210.03629>
- Zheng, Z., Ning, K., Wang, Y., Zhang, J., Zheng, D., Ye, M., & Chen, J. (2023). *A Survey of Large Language Models for Code: Evolution,*

Benchmarking, and Future Trends. Verfügbar 14. Mai 2026 unter <https://arxiv.org/abs/2311.10372>

Anhang

Im Rahmen dieser Arbeit wurden folgende ergänzende Unterlagen erstellt:

- **Anhang A:** Datenauswertung der Experteninterviews (Excel)
- **Anhang B:** Leitfaden für die Befragung

Datenauswertung der Experteninterviews

Category Title	Marked Text
03_01_Kognitiv_Altlasten	In der LOVC-Welt war das etwas anders: Da konnten Merkmale irgendwo enthalten sein, auch wenn sie im Modell gerade nicht verwendet wurden.
03_01_Kognitiv_Altlasten	Wenn man ein Modell direkt konvertieren will, hat man oft Altlasten, die das Modell behindern, weil beispielsweise die Prozedur oder das Beziehungswissen nicht ausgeführt werden.
03_01_Kognitiv_Altlasten	Die Werteräume dieser Merkmale wachsen über die Zeit stetig an.
03_02_Kognitiv_Syntax_Umdenken	Viele Kunden haben sich zum Beispiel eigene Funktionen (Z-Functions) programmiert, die im Beziehungswissen aufgerufen werden. Diese werden jetzt nicht mehr unterstützt.
03_02_Kognitiv_Syntax_Umdenken	Es gibt zwar BAdIs, mit denen wir einiges implementieren können, aber in der Clean-Core-Welt, in der alle Kunden jetzt unterwegs sein wollen, versucht man so etwas zu vermeiden.
03_02_Kognitiv_Syntax_Umdenken	Ein weiterer Punkt ist die von SAP empfohlene Modellierungstechnik für den AVC, die sich grundlegend von der im LOVC unterscheidet.
03_02_Kognitiv_Syntax_Umdenken	Diese sollen wir im AVC nun nicht mehr nutzen, sondern stattdessen mit Constraints arbeiten.
03_02_Kognitiv_Syntax_Umdenken	Man kann nichts direkt übernehmen. Auch wenn die Syntax eins zu eins gleich bleibt, muss ein neues Objekt generiert werden, da in den Eigenschaften des Objekts hinterlegt ist, ob es sich um klassisches Beziehungswissen oder um AVC handelt.
03_02_Kognitiv_Syntax_Umdenken	Der LOVC kommt mit nicht klassifizierten Merkmalen klar, der AVC hingegen nicht.
03_02_Kognitiv_Syntax_Umdenken	AVC an gewissen Stellen anders verhält als der LOVC.
03_02_Kognitiv_Syntax_Umdenken	Systemverhalten hat sich leicht geändert. Dieses veränderte Verhalten macht es oft notwendig, den Code anders zu schreiben oder um Dinge zu ergänzen, die vorher nicht da waren.
03_02_Kognitiv_Syntax_Umdenken	Das ist ein grundlegender Unterschied im Systemverhalten, der zu abweichenden Konfigurationsergebnissen führen kann und den man bei der Migration berücksichtigen muss.
03_02_Kognitiv_Syntax_Umdenken	Im AVC kann ich das nicht mehr spezifisch definieren. Im AVC werden immer alle Merkmale zueinander eingeschränkt.
03_02_Kognitiv_Syntax_Umdenken	Wenn ich also genau dasselbe Constraint wie vorher nun im AVC aufrufe, resultiert daraus möglicherweise ein ganz anderes Systemverhalten.
03_02_Kognitiv_Syntax_Umdenken	Das ist ein extremer Performance-Killer, den man laut SAP vermeiden soll.
03_03_Kognitiv_Fehler_Menschlich	Und am Ende war die Datei trotzdem fehlerhaft.
04_01_Tool_Konkrete_Anforderung	Man könnte sich vorstellen, diesen Ergebnisvergleich zu automatisieren oder von einer KI durchführen zu lassen.

04_01_Tool_Konkrete_Anforderung	Die KI könnte hierbei vielleicht noch bestimmte Hürden der Testautomatisierung überwinden.
04_01_Tool_Konkrete_Anforderung	Vielleicht könnte ein KI-Bot sich die alten Aufträge schnappen und aus den drei Einzelaufträgen automatisch ein gebündeltes Set bilden.
04_01_Tool_Konkrete_Anforderung	Man könnte beispielsweise einen Parser entwickeln, der die Syntax anhand fester Regeln übersetzt. Die KI sehe ich mittlerweile eher auf einer höheren Flugebene als beratendes Tool, das Zusammenhänge aufzeigt und Verbesserungspotenziale im Modell identifiziert.
04_01_Tool_Konkrete_Anforderung	Wenn ich ein Analysetool hätte, das so etwas erkennt, wäre das toll.
04_01_Tool_Konkrete_Anforderung	Die KI könnte so etwas erkennen und Ratschläge geben, wie: "Du machst die pauschale Bewertung am Anfang, setze sie doch ans Ende" oder "Du hast hier x Überschreibungen, die du vermeiden könntest, wenn du die Bedingungssteile präziser einschränkst, damit Sonderfall B nicht mehr im Sonderfall A enthalten ist."
04_01_Tool_Konkrete_Anforderung	Die KI könnte dann feststellen: "Die Prozedur an Position 10 wird im Kontext der anderen Prozeduren nie relevant sein, du kannst sie herausnehmen oder musst sie anders einsortieren."
04_01_Tool_Konkrete_Anforderung	dass die KI auch weiterhin zum Übersetzen genutzt wird.
04_01_Tool_Konkrete_Anforderung	fände ich es aber sehr gut, wenn du diese beratende Flugebene in dein Tool integrieren könntest.
04_01_Tool_Konkrete_Anforderung	wenn ich als Nutzer die KI zu meinem aktuellen Modell oder einer Funktion befragen könnte.
04_01_Tool_Konkrete_Anforderung	Die KI könnte beispielsweise den vorhandenen Code kommentieren.
04_01_Tool_Konkrete_Anforderung	Eine KI könnte hier automatisch Kommentare generieren, weil sie die Merkmale und die zugehörigen Beschreibungstexte miteinander verknüpft.
04_01_Tool_Konkrete_Anforderung	Es wäre cool, wenn eine KI in diese Z-Functions hineinschauen und analysieren könnte, was diese Funktion genau macht. Darauf aufbauend könnte sie vorschlagen, wie man diese Funktion im neuen System über ein BAdI lösen könnte.
04_01_Tool_Konkrete_Anforderung	Was extrem wertvoll wäre, ist, wenn die KI den Schritt von Vorbedingungen hin zu Constraints übernehmen könnte.
01_01_Prozess_Schritt_Manuell	Also musste der Mitarbeiter von Hand Bewertungen für die drei Modelle vornehmen, damit am Ende alles zusammenpasst
01_01_Prozess_Schritt_Manuell	Meistens schränke ich dort in Tabellenform die Werte zueinander ein und definiere gültige Kombinationen von Merkmalswerten.
01_01_Prozess_Schritt_Manuell	Man lädt sein LOVC-Modell dort hinein und kann es dann auf die Eignung für den AVC analysieren.
01_01_Prozess_Schritt_Manuell	Das ist quasi der erste Schritt: Man bekommt seine To-Dos aufgezeigt, also was im Beziehungswissen angepasst werden muss, und das Tool übernimmt die Massenanlage des Beziehungswissens.

01_01_Prozess_Schritt_Manuell	kann es anschließend aufräumen.
01_01_Prozess_Schritt_Manuell	Dafür muss ich die ganzen Vorbedingungen, die an den Werten hängen, analysieren und auswerten, was sie aussagen.
01_01_Prozess_Schritt_Manuell	Dort erstelle ich dann ein tabellenbasiertes Beziehungswissen für das jeweilige Produkt,
01_01_Prozess_Schritt_Manuell	erst einmal völlig losgelöst vom vorhandenen Konfigurationsmodell aus einer neutralen Sicht verstehen.
01_01_Prozess_Schritt_Manuell	fände ich es aber sehr gut, wenn du diese beratende Flugebene in dein Tool integrieren könntest.
01_01_Prozess_Schritt_Manuell	Dann habe ich geprüft, ob sich das deckt oder ob ich einen Denkfehler habe.
01_02_Prozess_Toolbruch	Meistens baue ich mir dafür eine große Excel-Tabelle auf.
02_01_Zeit_Dauer_Konkret	Sie haben ein einfaches bis mittleres Modell in drei bis vier Tagen migriert.
02_01_Zeit_Dauer_Konkret	Ich würde sagen, das macht etwa 20 % der Arbeit aus, der Großteil entfällt auf die Wandlung der Vorbedingungen in Constraints.
02_01_Zeit_Dauer_Konkret	20 % für die Merkmalswelt, 40 % für die Analyse und den Excel-Aufbau und der Rest entfällt auf die eigentliche Umsetzung.
02_01_Zeit_Dauer_Konkret	ein Kollege hat dort vier Monate lang in Vollzeit eine Excel-Tabelle aufgebaut, nur um die Vorbedingungen eines einzigen Modells zu analysieren.
02_01_Zeit_Dauer_Konkret	Diese Vorbedingungswelt durch constraint-basierte Modellierung abzulösen, ist eigentlich die Hauptarbeit bei dieser Migration.
02_02_Zeit_Flaschenhals	Ein Großteil der Arbeit besteht dabei darin, die vorab genannten Vorbedingungen durch Constraints abzulösen.
02_02_Zeit_Flaschenhals	Dieser Transfer also syntaktische Vorbedingungen in eine Tabellenform zu bringen und diese Tabellen dann in Constraints umzuwandeln macht ungefähr zwei Drittel der Arbeit aus.
02_02_Zeit_Flaschenhals	der Großteil entfällt auf die Wandlung der Vorbedingungen in Constraints.
02_02_Zeit_Flaschenhals	zu großen Teilen wird es dann zu einer reinen Umsetzungsaufgabe.
02_02_Zeit_Flaschenhals	20 % für die Merkmalswelt, 40 % für die Analyse und den Excel-Aufbau und der Rest entfällt auf die eigentliche Umsetzung.
Explizite_Tool_Nennung	Wenn man sich für eine direktere Migration entscheidet, gibt es von SAP mittlerweile ein Migration Cockpit, das beim Umstieg hilft.
Explizite_Tool_Nennung	im Trace
Testen	Es ist rein manuelles Testen.
Testen	durchaus Strategien für automatisches Testen.
Testen	letztes Jahr für den Kunden ein Konzept für ein mögliches Testtool geschrieben.
Testen	Der Prozess sieht so aus: Man nimmt sich einen vorhandenen Testauftrag als Basis und nutzt eine Migrationstabelle für die Merkmale.
Testen	Ich weiß also, was aus dem alten Merkmal A in meinem neuen Modell geworden ist beispielsweise Merkmal B. Damit gehe ich in die Konfiguration und lege einen Kundenauftrag im neuen System mit den neuen Merkmalsbewertungen an. Den Auftrag speichere ich ab und vergleiche dann den alten Kundenauftrag mit dem neuen.

Testen	Wir haben also die Konstellation, dass aus drei alten Objekten ein neues Objekt geworden ist. Diesen Schritt konnte das geplante Testtool bisher nicht abbilden.
Testen	Das Tool kann zwar das Fahrzeug in ein Testobjekt migrieren, aber die Batterie müsste von Hand nachkonfiguriert werden.
Komplexität_Modellgröße	Bei kleinen Modellen, wie die Kollegen sie aktuell betreuen, gibt es teilweise nur etwa 20 bis 30 Merkmale. Dort ist eine direkte Migration natürlich deutlich leichter möglich. haben wir letztes Jahr einen Proof of Concept für das Migrate-Tool gemacht. Dabei sind wir bei der reinen Syntaxübersetzung bereits auf Hürden gestoßen und haben uns gefragt, ob eine KI für die reine Syntaxübersetzung wirklich das richtige Werkzeug ist. In der Zwischenzeit haben wir auch andere Ansätze gesehen. Man könnte beispielsweise einen Parser entwickeln, der die Syntax anhand fester Regeln übersetzt. Die KI sehe ich mittlerweile eher auf einer höheren Flugebene als beratendes Tool, das Zusammenhänge aufzeigt und Verbesserungspotenziale im Modell identifiziert.
Limitierung_KI_Tool	